VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ

Projektová dokumentace

Implementace překladače imperativního jazyka IFJ25

Tým *xliskah00*, varianta *TRP-izp*

Hana Liškařová	**xliskah00**	**25%**
Matěj Kurta	xkurtam00	25%
Martin Bíško	xbiskom00	25%
Šimon Dufek	xdufeks00	25%

Implementovaná rozšíření: CYCLES, BOOLTHEN, OPERATORS, FUNEXP

3. prosince 2025

Obsah

1 Úvod

Cílem projektu bylo navrhnout a implementovat překladač imperativního jazyka IFJ25. Překladač musí pokrývat všechny fáze klasického kompilátoru – lexikální analýzu, syntaktickou analýzu, sémantickou analýzu a generování mezikódu IFJcode25. Tato dokumentace nepopisuje jen jednotlivé moduly, ale i postup, kterým jsme k výslednému řešení došli.

2 Práce v Týmu

2.1 Rozdělení práce mezi členy týmu

2.1.1 Hana Liškařová (`xliskah00`)

- Návrh konečného automatu lexikální analýzy a implementace celé lexikální analýzy.
- Tvorba prezentace k obhajobě.
- Většinový podíl na tvorbě dokumentace.
- Návrh a implementace fungování sémantické analýzy. Implementace `semantic_pass1` - průchod AST od shora dolů, naplnění tabulky symbolů a implementace základních sémantických kontrol.
- Kontrola a formátování souborů před odevzdáním. Přidávání doxygen hlaviček souborů.

2.1.2 Matěj Kurta (`xkurtam00`)

- Návrh a implementace tabulky symbolů a jejích operací.
- Návrh a implementace obecného zásobníku a jeho operací.
- Implementace `semantic_pass2` v sémantické analýze - průchod AST zdola nahoru a implementce typových kontrol.

2.1.3 Martin Bíško (`xbiskom00`)

- Návrh a implementace syntaktické analýzy a konstrukce AST.
- Implementace precedenční analýzy výrazů.

2.1.4 Šimon Dufek (`xdufeks00`)

- Návrh a implementace struktury AST a jeho operací.
- Návrh a implementace generátoru kódu.

2.1.5 Společná práce

- Dokumentace.

3 Struktura projektu

Níže je zobrazená struktura odevzdaného souboru s projektem:

```
projekt/
|-- Makefile
|-- dokumentace.pdf
|-- ast.c
|-- ast.h
|-- builtins.c
|-- builtins.h
|-- codegen.c
|-- codegen.h
|-- error.c
|-- error.h
|-- expressions.c
|-- expressions.h
|-- main.c
|-- parser.c
|-- parser.h
|-- rozdeleni
|-- rozsireni
|-- scanner.c
|-- scanner.h
|-- scope_stack.c
|-- scope_stack.h
|-- semantic.c
|-- semantic.h
|-- stack.c
|-- stack.h
|-- string.c
|-- string.h
|-- symtable.c
|-- symtable.h
|-- token.c
`-- token.h
```

3.1 Popis obsahu jednotlivých souborů

- **Makefile** – skript pro překlad projektu. Kompiluje všechny soubory do binárky `compiler` při `make`, obsahuje také pomocné cíle pro čištění (`make clean`) a testování.
- **dokumentace.pdf** – tento soubor. Projektová dokumentace ve formátu PDF.
- **main.c** – vstupní bod programu. Zajišťuje inicializaci, volání lexikální analýzy, syntaktické analýzy, sémantické analýzy a generátoru kódu, a na závěr uvolnění všech datových struktur.
- **scanner.c** a **scanner.h** – implementace lexikální analýzy jako konečného automatu. Čte znaky ze standardního vstupu a vytváří seznam tokenů, který slouží jako vstup pro syntaktickou analýzu.
- **token.c** a **token.h** – definice struktury tokenu a implementace obousměrného seznamu tokenů. Zajišťuje vytváření, průchod, mazání a základní pomocné operace nad sekvencí tokenů a tokenem samotným.

- **parser.c** a **parser.h** – syntaktická analýza. Zpracovává seznam tokenů podle gramatických pravidel a vytváří abstraktní syntaktický strom (AST).
- **expressions.c** a **expressions.h** – analýza výrazů založená na precedenční tabulce. Využívá zásobník a tokeny k parsování aritmetických a logických výrazů a převádí je do AST uzlů.
- **ast.c** a **ast.h** – definice datových struktur pro abstraktní syntaktický strom (AST) a funkce pro jeho vytváření, práci s jednotlivými uzly a těly, případně výpisy.
- **string.c** a **string.h** – implementace vlastního dynamického řetězce. Zajišťují alokaci, realokaci, konkatenaci, kopírování, mazání a výpis textu, včetně podpory pro generátor kódu.
- **error.c** a **error.h** – definice chybových kódů projektu a společná funkce `error` pro hlášení chyb na `stderr` a návrat odpovídajícího kódu.
- **symtable.c** a **symtable.h** – implementace tabulky symbolů založené na implicitně zřetězené hašovací tabulce. Uchovává informace o funkcích, proměnných a jejich vlastnostech (typ, rozsah, parametry apod.) pro potřeby sémantické analýzy.
- **stack.c** a **stack.h** – obecný zásobník (LIFO) nad ukazateli. Používá se například v analyzátoru výrazů a při práci s rámci sémantické analýzy.
- **scope_stack.c** a **scope_stack.h** – specializovaný zásobník rozsahů (scope stack) pro sémantickou analýzu. Ukládá ukazatele na lokální tabulky symbolů jednotlivých bloků a funkcí, čímž umožňuje kontrolu redeklarací a stínění identifikátorů.
- **builtins.c** a **builtins.h** – registrace vestavěných funkcí jmenného prostoru `Ifj.*` do globální tabulky symbolů (např. `Ifj.read_str`, `Ifj.write`). Ukládají se zejména názvy a arita funkcí.
- **semantic.c** a **semantic.h** – implementace první průchodové sémantické analýzy. Prochází AST, plní globální a lokální tabulky symbolů, kontroluje existenci `main()`, redeklarace, počet argumentů a základní typové kolize u literálových výrazů. - OPRAVIT AŽ BUDE HOTOVÉ
- **codegen.c** a **codegen.h** – generátor výsledného kódu. Rekurzivně prochází AST a vytváří cílový kód ve formátu `IFJcode25`, který je ukládán do dynamického řetězce a na konci vypsán na standardní výstup.
- **rozdeleni** – textový soubor s procentuálním podílem jednotlivých členů týmu.

4 Návrh a implementace

4.1 Sdílené

4.1.1 Chybové kódy a hlášení chyb (`error.c`, `error.h`)

Moduly `error.h` a `error.c` zajišťují jednotnou správu chyb v celém projektu. Soubor `error.h` definuje sadu konstant pro návratové kódy překladače, které odpovídají zadání.

V `error.c` je implementována funkce `error(int exit_code, const char *fmt, ...)`, která slouží jako centrální bod pro hlášení chyb:

- přijímá návratový kód a formátovací řetězec ve stylu `printf()`,
- pomocí `vfprintf()` vypisuje na `stderr` zprávu ve tvaru "`Error:...`",
- po vypsání zprávy vrací předaný `exit_code`.

To v jednom kroku zajistí vypsání srozumitelné chybové hlášky na standardní chybový výstup a zároveň vrácení správného kódu až do `main()`.

4.1.2 Hlavní běh programu (`main.c`)

Soubor `main.c` je vstupním bodem překladače a skládá dohromady jednotlivé fáze z ostatních modulů.

Na začátku se inicializuje seznam tokenů `DLListTokens` a funkce `scanner(stdin, &token_list)` provede lexikální analýzu vstupu. Při chybě vrací `ERR_LEX` (nebo jiný kód) a `main()` tento kód propaguje ven po uvolnění seznamu tokenů.

Pokud lexikální analýza skončí úspěšně, nastaví se aktivní prvek seznamu na první token a vytvoří se kořen AST pomocí `ast_init()`. Funkce `parser(&token_list, ast_tree, GRAMMAR_PROGRAM)` zpracuje tok tokenů podle gramatiky - při syntaktické chybě skončí program s kódem `ERR_SYN`.

Na vytvořený AST navazuje sémantická analýza `semantic_pass1(ast_tree)`, která zbuduje tabulku symbolů a kontroluje základní sémantické vlastnosti programu (např. existenci `main()`, redeklarace, počty argumentů).

V případě úspěchu je alokována struktura `generator`, inicializovaná funkcí `init_code(gen, ast_tree)`. Následně `generate_code(gen, ast_tree)` projde AST a uloží výsledný `IFJcode25` do dynamického řetězce `gen->output`, který je vypsán na standardní výstup pomocí `fputs()`.

Na závěr `main()` uvolní generátor i seznam tokenů (`DLLTokens_Dispose()`) a končí s návratovým kódem `SUCCESS`.

4.2 Lexikální analyzátor

Lexikální analyzátor převádí proud znaků ze standardního vstupu na sekvenci tokenů, se kterou dále pracuje syntaktická analýza. Čte po jednom znaku ze vstupu - nikdy nedrží celý vstup v paměti a pamatuje si jen aktuální stav automatu, pozici ve vstupu (řádek, sloupec) a rozpracovaný token.

Rozhraní tvoří funkce `scanner(FILE *in, DLListTokens *list)`, která uvnitř opakovaně volá interní funkci `get_next_token()`. Každý nově rozpoznaný token se rovnou ukládá do obousměrného seznamu `DLListTokens`, který je pak předán parseru.

Čtení znaků zajišťují pomocné funkce `get_char()` a `pushback()`, které kromě samotného znaku aktualizují i aktuální pozici a umožňují vrátit jeden znak zpět (typicky při lookaheadu u operátorů a čísel). Speciálně jsou řešeny konce řádků: kombinace `\r\n` i jednotlivé znaky `\r` / `\n` se vždy normalizují na jeden token `T_EOL`.

Z hlediska je scanner rozdělen na několik větví podle typu lexému:

- identifikátory a klíčová slova (včetně speciálních globálních identifikátorů začínajících na __),
- číselné literály (celá čísla v desítkové a šestnáctkové soustavě, desetinná čísla a exponenty),
- řetězce (klasické i víceřádkové),
- operátory a oddělovače,
- komentáře a bílé znaky.

Logika je rozdělená na dvě části: vlastní rozpoznání lexému konečným automatem a následné zpracování hodnoty. Například u čísel automat jen hlídá syntaxi (povolené znaky, správné umístění teček a exponentu), ale samotný převod na `long long` nebo `double` se provádí až na konci pomocí `strtoll()` / `strtod()`.

4.2.1 Konečný stavový automat lexikální analýzy

Jelikož tady v dokumentaci nejde návrh konečného automatu správně vidět, zde je odkaz na obrázek nahraný na Google drive. Jinak návrh naleznete na poslední straně tohoto dokumentu.

4.3 Syntaktický analyzátor

Hlavní funkcí syntaktického analyzátoru je rekurzivní funkce `parser`, která zpracovává tokeny a podle gramatických pravidel zhodnocuje, zda nedochází k syntaktické chybě. Při průchodu dochází i ke generování abstaktního syntaktického stromu (AST), který je následně využit pro sémantickou analýzu a generování kódu. Pro zpracování gramatických pravidel je vytvořen enum `grammar_rule`, který obsahuje data podle gramatických pravidel.

4.3.1 Gramatická pravidla

1. $\langle program \rangle \rightarrow \langle import \rangle \langle class\_list \rangle$
2. $\langle import \rangle \rightarrow$ `import "ifj25"for Ifj`
3. $\langle class\_list \rangle \rightarrow \langle class\_def \rangle \langle class\_list \rangle \mid \varepsilon$
4. $\langle class\_def \rangle \rightarrow$ `class ID` $\langle body \rangle$
5. $\langle body \rangle \rightarrow$ `{` $\langle command\_list \rangle$ `}`
6. $\langle command\_list \rangle \rightarrow \langle command \rangle \langle command\_list \rangle \mid \varepsilon$
7. $\langle command \rangle \rightarrow \langle fun\_def \rangle \mid \langle fun\_call \rangle \mid \langle ifj\_fun\_call \rangle \mid \langle declaration \rangle \mid \langle assignment \rangle \mid \langle condition \rangle \mid \langle for \rangle \mid \langle while \rangle \mid \langle return \rangle$
8. $\langle fun\_def \rangle \rightarrow$ `static ID` $\langle params \rangle \langle body \rangle$
9. $\langle params \rangle \rightarrow$ `(` $\langle param\_list \rangle$ `)`
10. $\langle param\_list \rangle \rightarrow$ `ID` $\langle param\_list' \rangle \mid \varepsilon$
11. $\langle param\_list' \rangle \rightarrow$ `,` `ID` $\langle param\_list' \rangle \mid \varepsilon$
12. $\langle declaration \rangle \rightarrow$ `var ID`
13. $\langle assignment \rangle \rightarrow$ `ID` = $\langle expression \rangle$
14. $\langle expression \rangle \rightarrow \langle expression \rangle \langle exp\_operator \rangle \langle expression \rangle \mid \langle value \rangle \mid \langle fun\_call \rangle \mid \langle ifj\_fun\_call \rangle$
15. $\langle exp\_operator \rangle \rightarrow$ + | − | * | /
16. $\langle condition \rangle \rightarrow$ `if` $\langle cond\_expression \rangle \langle body \rangle$ `else` $\langle body \rangle$
17. $\langle cond\_expression \rangle \rightarrow$ `(` $\langle expression \rangle \langle cond\_operator \rangle \langle expression \rangle$ `)`
18. $\langle cond\_operator \rangle \rightarrow$ > | >= | < | <= | == | != | `is`
19. $\langle while \rangle \rightarrow$ `while` $\langle cond\_expression \rangle \langle body \rangle$
20. $\langle for \rangle \rightarrow$ `for (` `ID in` $\langle expression \rangle$ `..` $\langle expression \rangle$ `)` $\langle body \rangle \mid$ `for (` `ID in` $\langle expression \rangle$ `...` $\langle expression \rangle$ `)`
21. $\langle fun\_call \rangle \rightarrow$ `ID` $\langle args \rangle$
22. $\langle ifj\_fun\_call \rangle \rightarrow$ `Ifj .` `ID` $\langle args \rangle$
23. $\langle args \rangle \rightarrow$ `(` $\langle arg\_list \rangle$ `)`
24. $\langle arg\_list \rangle \rightarrow \langle expression \rangle \langle arg\_list' \rangle \mid \varepsilon$

25. $\langle arg\_list' \rangle \rightarrow$, $\langle expression \rangle \langle arg\_list' \rangle \mid \varepsilon$
26. $\langle return \rangle \rightarrow$ `return` $\langle return\_value \rangle$
27. $\langle return\_value \rangle \rightarrow$ `ID` $\mid \langle fun\_call \rangle \mid \langle ifj\_fun\_call \rangle \mid \langle value \rangle$

4.3.2 LL1 tabulka

4.3.3 Precedenční tabulka výrazů

	$*, /$	$+, -$	rel	is	eq	(	id/const	)	$
$*, /$	$>$	$>$	$>$	$>$	$>$	$<$	$<$	$>$	$>$
$+, -$	$<$	$>$	$>$	$>$	$>$	$<$	$<$	$>$	$>$
rel	$<$	$<$	$>$	$>$	$>$	$<$	$<$	$>$	$>$
is	$<$	$<$	$<$	$>$	$>$	$<$	$<$	$>$	$>$
eq	$<$	$<$	$<$	$<$	$>$	$<$	$<$	$>$	$>$
(	$<$	$<$	$<$	$<$	$<$	$<$	$<$	$=$	
id/const	$>$	$>$	$>$	$>$	$>$			$>$	$>$
)	$>$	$>$	$>$	$>$	$>$			$>$	$>$
$	$<$	$<$	$<$	$<$	$<$	$<$	$<$		

4.3.4 Precedenční pravidla

- $E \rightarrow E * E$
- $E \rightarrow E / E$
- $E \rightarrow E + E$
- $E \rightarrow E - E$
- $E \rightarrow E < E$
- $E \rightarrow E \leq E$
- $E \rightarrow E > E$
- $E \rightarrow E \geq E$
- $E \rightarrow E == E$
- $E \rightarrow E \neq E$
- $E \rightarrow E$ is E
- $E \rightarrow (E)$
- $E \rightarrow i$

	import	class	}	static	{	ID	Ifj	var	if	for	while	return	(	)	,	=	+	-	*	/	INT	FLOAT	STRING	null	$
⟨*program*⟩	1																								
⟨*import*⟩	2																								
⟨*class_list*⟩		3																							ε
⟨*class_def*⟩		4																							
⟨*body*⟩			5																						
⟨*command_list*⟩				ε	6	6	6	6	6	6	6	6													
⟨*command*⟩					7	7	7	7	7	7	7	7													
⟨*fun_def*⟩					8																				
⟨*params*⟩													9												
⟨*param_list*⟩						10								ε											
⟨*param_list'*⟩														ε	11										
⟨*declaration*⟩								12																	
⟨*id_suffix*⟩													21			13									
⟨*expression*⟩						14	14						14								14	14	14	14	
⟨*expression'*⟩														ε	ε		15	15	15	15					
⟨*exp_operator*⟩																	16	16	16	16					
⟨*condition*⟩									17																
⟨*cond_expr*⟩													18												
⟨*while*⟩											19														
⟨*for*⟩										20															
⟨*ifj_call*⟩							22																		
⟨*args*⟩													23												
⟨*arg_list*⟩						24	24						24	ε							24	24	24	24	
⟨*arg_list'*⟩														ε	25										
⟨*return*⟩												26													
⟨*ret_value*⟩						27	27														27	27	27	27	

4.3.5 Zpracovávání výrazů

Výrazy jsou zpracovány pomocí funkce `parse_expr`, která prochází list tokenů a vytváří strom výrazu. Ke zpracovávání výrazů se používá pomocný zásobník a precedenční tabulka výrazů.

Na začátku se na zásobník vloží znak **$** a následně se porovnávají tokeny s vrchním znakem na zásobníku. Tyto dva znaky se zpracují dle precedenční tabulky a podle výsledku vykoná akci. Pokud výstupem je **<** nebo **=**, vloží znak na vrchol zásobníku, pokud je znak **>**, tak se výraz zredukuje dle pravidel. Pokud ale v precedenční tabulce není žádný znak, program skončí s kódem `ERR_SYN`.

Zredukování výrazů probíhá tak, že se vezmou vrchní symboly zásobníku a zredukují se dle precedenčních pravidel, kde **i** je ID, konstanta nebo konkrétní hodnota a **E** je výraz.

Po průchodu celého výrazu na zásobníku zůstane jeden konečný výraz, který je i výstupem funkce.

4.4 Semantický analyzátor

Sémantická analýza je implementovaná v souborech `semantic.c` a `semantic.h` a používá tabulkou symbolů (`symtable.*`), zásobník rozsahů (`scope_stack.*`) a registraci vestavěných funkcí (`builtins.*`). Z pohledu zbytku projektu má jedno hlavní vstupní rozhraní `semantic_pass1(ast_tree)`, které po úspěšném parsování spustí celou sémantickou analýzu.

Uvnitř je zpracování rozděleno do **dvou průchodů** přes abstraktní syntaktický strom (AST): první průchod naplňuje tabulku symbolů, druhý průchod pak řeší konkrétní použití identifikátorů a typové kontroly výrazů.

4.4.1 Tabulky symbolů

Díky tomu, že v jazyce `Wren` nelze definovat vnořené funkce, bylo možné implementovat dva "typy"samotné tabulky symbolů. Prvním je globální tabulka obsahující **definice funkcí, definice vestavěných funkcí a globální proměnné**. Druhým typem jsou tabulky daných rozsahů (scopes).

Přesné rozdělení tabulek vypadá takto:

- globální tabulka funkcí (uživatelských i `Ifj.*`), kde klíčem je jméno + arita,
- zásobník lokálních tabulek proměnných, reprezentovaný `scope_stack`, který odráží vnoření bloků v AST.

4.4.2 První průchod AST - zhora dolů - `semantic_pass1`

Funkce `semantic_pass1` nejprve vytvoří kontext sémantické analýzy (struktura `semantic`) a inicializuje globální tabulku funkcí. Do té se pomocí **`builtins_install()`** zaregistrují vestavěné funkce `Ifj.*` v formátu (název, arita, očekávané typy parametrů).

Poté nastane sběr hlaviček uživatelských funkcí, getterů a setterů. Pomocná funkce (`collect_headers`) projde AST třídy a bloky a pro každý deklarovaný symbol vytvoří záznam v **globální tabulce**.

Klíč symbolu se zkládá z kombinace jména a arity, což umožňuje podporu přetěžování podle počtu parametrů.

Následně se průchod vrátí na těla bloků a začne zpracovávat lokální proměnné. Správu zanoření - *scope* řeší `scope_stack`, který drží zásobník ukazatelů na jednotlivé lokální tabulky symbolů (`symtable`).

Při vstupu do bloku proběhne `scopes_push()` a pro daný blok se vytvoří nová lokální tabulka. Při opuštění bloku `scopes_pop()` tabulku uvolní. Deklarace proměnných v aktuálním bloku se ukládají přes `scopes_declare_local()`, která zároveň hlídá redeklaraci ve stejném rozsahu.

V rámci `semantic_pass1` se provedou i základní kontroly nevyžadující přesnou znalost typů:

- ověření existence funkce `main()` s nulovou aritou,
- kontrola redeklarace funkcí a proměnných,

- kontrola, že `break` a `continue` se vyskytují pouze uvnitř cyklů,
- základní kontroly `return` uvnitř funkcí.

Výstupem prvního průchodu je globální tabulka funkcí a sada lokálních tabulek proměnných se správným zanořením.

4.4.3 Druhý průchod AST - `semantic_pass2`

Druhý průchod provádí kontrolu typové správnosti a řešení identifikátorů nad již kompletním stromem AST. Přitom používá informace nashromážděné v prvním průchodu (tabulky funkcí, přístupové metody, vestavěné funkce a deklarace třídních členů). Pass 2 znovu inicializuje zásobník rámců a při vstupu do každého bloku vytváří nový rozsah viditelnosti.

Rozpoznávání identifikátorů Pro každý použitý identifikátor funkce `sem2_resolve_identifier` kontroluje:

- lokální proměnná nebo parametr (v `scope_stack`),
- getter/setter s daným názvem (v globální tabulce),
- globální proměnná podle vzoru `__name` (automaticky akceptována

Typová kontrola výrazů Funkce `sem2_visit_expr` vyhodnocuje typy výrazů:

- aritmetické operace: numerické typy s unifikací (`int` + `num` → `num`),
- relační operátory: pouze numerické operandy,
- logické operátory: pouze booleovské operandy,
- operátor `is`: pravá strana musí být `Num`, `String` nebo `Null`.

Kontrola volání funkcí Vestavěné i uživatelské funkce se ověřují podle signatur `name#arity` uložených v tabulce z prvního průchodu.

- vestavěné funkce (`Ifj.*`): kontrola přesné arity,
- uživatelské funkce: kontrola existence signatury `name#arity` nebo správné arity .

Výstup druhého průchodu

- ověřená typová korektnost programu,
- aktualizované informace o lokálních i globálních proměnných,
- doplněné `cg_name` pro codegen,
- seznam globálních proměnných dostupný přes `semantic_get_globals()`.

4.5 Generátor kódu

Generátor kódu je implementován v souboru `codegen.c` a používá přístup **Stack-based evaluation** pro překlad **Abstraktního Syntaktického Stromu (AST)** do instrukcí pro virtuální stroj **IFJcode25**. Hlavní vstupní rozhraní je `generate_code(generator gen, ast ast)`, které se spustí po úspěšné sémantické analýze.

4.5.1 Klíčové Struktury a Konvence

Generátor kódu používá strukturu `generator` pro udržení stavu a řízení toku:

- **`output`**: Dynamický řetězec, cílový výstup IFJcode25.
- **`counter`**: Čítač pro generování unikátních návěští a dočasných proměnných (např. `whileStart123`).
- **`loop_stack`**: Zásobník pro sledování návěští `start_label` a `end_label` aktuálně vnořených cyklů (`while`), nezbytný pro implementaci `break` a `continue`.
- **Dočasné GF proměnné**: Sada globálních dočasných proměnných (`GF@tmp1`, `GF@fn_ret`, `GF@tmp_type_l/r`) sloužících pro uchování mezivýsledků a typových kontrol.
- **Adresování**: Funkce `var_frame_parse` automaticky doplňuje prefixy rámců (`GF@` pro globální, `LF@` pro lokální) pro správné adresování.

4.5.2 Fáze Generování Kódu

Fáze 1: Inicializace (`init_code`) Tato fáze připravuje kód a deklaruje globální rozsah:

- Vypíše hlavičku `.IFJcode25`.
- Generuje instrukce `DEFVAR` pro všechny dočasné globální proměnné.
- Volá `sem_def_globals`, která vygeneruje `DEFVAR` a `MOVE name nil@nil` pro všechny globální proměnné programu.

Fáze 2: Hlavní Průchod a Ukončení (`generate_code`)

- **Generování `main`**: Nejprve je vygenerována funkce `main` (`generate_main`), která je implicitním vstupním bodem programu.
- **Generování zbytku**: Poté rekurzivně vygeneruje kód pro všechny ostatní funkce a bloky (`generate_block`).

4.5.3 Generování Výrazů a Konverze Typů

Generování výrazů (`generate_expression_stack`) klade velký důraz na zajištění dynamické typové kompatibility.

1. **Sčítání / Konkatenace (`AST_ADD`)**: Využívá `generate_add_conversion` Pro odhalení, zda se jedná o Sčítání, nebo konkatenaci.
2. **Násobení / Opakování (`AST_MUL`)**: Využívá `generate_mul_conversion`. Pokud se na levé straně výrazu nachází string a na pravé int, generuje se cyklus pro **opakování řetězce** (`generate_repetition`).
3. **Dělení (`AST_DIV`)**: Vždy konvertuje oba numerické operandy na `float` před instrukcí `DIV`.
4. **Běhová kontrola typů**: Funkce `generate_type_check` používá instrukci `TYPE` k ověření kompatibility typů a skok `JUMPIFNEQ` na chybové návěští `ERR26`.
5. **Auto-korekce**: `process_auto_corecion` zajišťuje, že při numerických operacích jsou oba operandy (pokud je to nutné) převedeny na `float`.

4.5.4 Generování Řídících Struktur a Vestavěných Funkcí

Vlastní funkce

- Generují návěští, `CREATEFRAME`, `PUSHFRAME`.
- Parametry se načítají ze zásobníku volání pomocí `POPS` do lokálních proměnných.
- Návratová hodnota je uložena do `GF@fn_ret`. Ukončení probíhá pomocí `POPFRAME` a `RETURN`.

Řízení toku

- **`if/else`**: Používá `JUMPIFEQ GF@tmp_if bool@false else_label`.
- **`while` cyklus**: Na `loop_stack` se ukládají návěští `whileStart` a `whileEnd`. Příkazy **`break`** a **`continue`** generují `JUMP` na příslušná návěští ze zásobníku.

Vestavěné funkce (`generate_ifjfunction`)

- **`ifj.write`**: Obsahuje logiku pro kontrolu, zda je `float` celým číslem, s následnou konverzí `FLOAT2INT` pro čistý výpis celých čísel.
- **`ifj.substring`**: Implementuje podřetězec pomocí cyklu využívajícího `STRLEN`, `GETCHAR` a `CONCAT`.

5 Datové struktury

5.1 Dynamický řetězec

V projektu se často pracuje s textovými hodnotami, jako jsou vstupní lexémy nebo generovaný cílový kód. Proto jsme zavedli vlastní datový typ pro dynamické řetězce, který umožňuje manipulaci s textovými daty neznámé či měnící se délky. Tento datový typ je definován v rozhraní `string.h` a implementován v souboru `string.c`.

Řetězec se vytváří funkcí `string_create()`, která alokuje počáteční kapacitu (nebo `DEFAULT_SIZE`). Při nedostatku místa se interní pomocná funkce zvětší kapacitu na dvojnásobek. Základní operace jsou:

- `string_append_char()` – přidání jednoho znaku na konec,
- `string_append_literal()` – připojení C řetězce,
- `string_concat()` – konkatenace dvou dynamických řetězců,
- `string_clear()` – nastavení na prázdný řetězec,
- `string_destroy()` – uvolnění vnitřních dat i struktury,
- `string_to_file()` – zápis generovaného mezikódu do souboru.

5.2 Tabulka symbolů

Tabulka symbolů je implementována jako hashovací tabulka pro ukládání a následnou práci s informacemi. Implementována je v souborech `symtable.h` a `symtable.c`. Využívá otevřené adresování pro řešení kolizí. Používá známou hashovací funkci `djb2` kvůli její nízké koliznosti a tabulka používa fixnou velikost `SYMTABLE_SIZE`. Při vkládání nových symbolů se ingoruje `st_insert()` pokud symbol již existuje.

- `data_type` – typ dat, tedy druh hodnoty

- `symbol_type` – kategorie (proměnná, funkce…)
- `st_data` – struktura obsahující veškerá metadata symbolu, včetně typů, počtu parametrů, informací o rozsahu (scope) a odkazu na uzel AST
- `st_symbol` – reprezentace jedné položky v tabulce obsahující klíč, data a příznaky `occupied` a `deleted` pro správu kolizí
- `symtable` – hlavní struktura tabulky symbolů obsahující pole symbolů a informaci o počtu uložených prvků

Rozhraní tabulky:

- `st_hash()` – hashovací funkce implementující algoritmus djb2
- `st_init()` – inicializuje novou prázdnou tabulku symbolů a alokuje paměť
- `st_find()` – vyhledá symbol v tabulce podle klíče, vrátí ukazatel na symbol nebo NULL
- `st_insert()` – vloží nový symbol do tabulky, pokud ještě neexistuje; alokuje paměť pro klíč i data a nastaví základní atributy
- `st_get()` – získá datovou strukturu symbolu podle klíče, vrací `st_data`
- `st_free()` – uvolní veškerou alokovanou paměť tabulky, včetně klíčů, datových struktur a samotné tabulky
- `st_dump()` – vypíše lidsky čitelný obsah tabulky pro ladicí účely; zobrazí indexy, klíče, typy a parametry
- `st_foreach()` – iteruje přes všechny obsazené položky v tabulce a pro každou volá uživatelem definovanou callback funkci
- `my_strdup()` – pomocná funkce pro duplikování řetězců s alokací nové paměti

V projektu existuje jedna globální tabulka symbolů pro funkce, přístupové metody a globální proměnné a dále samostatné lokální tabulky pro jednotlivé bloky a funkce. Lokální tabulky jsou spravovány pomocí `scope_stack` (viz oddíl o zásobníku rozsahů).

5.3 Zásobník rozsahů (`scope_stack`)

Samotná tabulka symbolů (`symtable.c/h`) řeší uložení a vyhledávání symbolů v jednom rozsahu - globální tabulku funkcí nebo lokální proměnné uvnitř jedné funkce. Sémantická analýza ale pracuje s zanořenými bloky. Dle našeho návrhu je potřeba mít pro každý blok vlastní `symtable` a zároveň nad nimi udržovat informaci o aktuálním rozsahu (scope).

K tomu slouží pomocná struktura `scope_stack`, která nad obecnou tabulkou symbolů staví správu rozsahů (scopes). Je navázaný na náš obecný zásobník `stack`, ve kterém jsou uloženy ukazatele na `symtable*`. Každý prvek zásobníku tedy odpovídá jednomu bloku a uchovává symboly z tohoto bloku. Na vrcholu zásobníku je vždy aktuální (nejvnitřnější) rozsah.

Typický průběh v sémantické analýze je následující:

- při vstupu do nového bloku se zavolá `scopes_push()`, která vytvoří novou prázdnou `symtable` pro daný rozsah,
- nové lokální proměnné se deklarují přes `scopes_declare_local()`, která v aktuálním rámci zakáže redeklaraci stejného jména,

- při vyhledávání identifikátoru se používá `scopes_lookup()`, která prochází rámce od vrcholu dolů a respektuje stínění,
- při opuštění bloku se volá `scopes_pop()`, která daný rámec sejme a jeho `symtable` uvolní pomocí `st_free()`.

Globální tabulka symbolů (funkce programu a vestavěné `Ifj.*` a globály) je udržována samostatně jako jeden `symtable` mimo `scope_stack`.

5.4 Zásobník

Stejně jako u dynamického řetězce, několik oddělených částí projektu potřebuje pracovat s zásobníkem na principu LIFO. Rozhodli jsme se proto zavést jeden sdílený zásobník pro veškeré účely překladače.
Obecný zásobník je v implementován nad ukazateli. Je definován v souborech `stack.h` a `stack.c`.

Vnitřní reprezentace je jednosměrně vázaný seznam. Každý prvek `stack_item` obsahuje:

- `void *data` – ukazatel na uložená data libovolného typu,
- `stack_item *next` – odkaz na další prvek.

Struktura `stack` obsahuje pouze ukazatel `top` na vrchol zásobníku.
Rozhraní zásobníku:

- `stack_init()` – inicializace prázdného zásobníku,
- `stack_push()` – vložení ukazatele na vrchol,
- `stack_push_value()` – alokace a uložení kopie hodnoty,
- `stack_pop()` – odebrání vrcholu a vrácení jeho `data`,
- `stack_top()` – nahlédnutí na vrchol bez odebrání,
- `stack_is_empty()` – test, zda je zásobník prázdný,
- `stack_free()` – uvolnění všech uzlů.

Díky tomu, že zásobník pracuje nad obecnými ukazateli `void *`, lze stejnou implementaci znovu použít v různých částech překladače. Typová kontrola je řešena až na úrovni volajícího modulu pomocí přetypování ukazatelů na konkrétní struktury.

5.5 Token

Každý token reprezentuje jednu lexikální jednotku (klíčové slovo, identifikátor, literál, operátor, oddělovač, `EOL`, `EOF`) a nese svůj typ a případnou hodnotu. Definice je v `token.h`, implementace v `token.c`.
Struktura `struct token` obsahuje:

- `token_type type` – typ tokenu,
- `string value` – textová podoba lexému (např. identifikátor, řetězec),
- `double value_float` a `long long value_int` – numerická hodnota,
- `int depth` – pomocná hodnota pro zanoření blokových komentářů.

Typ `token_type` je rozlišen na:

- obecné typy: `T_NONE`, `T_EOF`, `T_EOL`,
- identifikátory
- klíčová slova
- literály
- operátory a oddělovače (aritmetické, relační, logické, závorky, čárky, rozsahové operátory).

Základní používané funkce nad tokenem:

- `token_create()` – alokace a inicializace nového tokenu,
- `token_clear()` – reset hodnot na výchozí stav,
- `token_destroy()` – uvolnění dynamického řetězce i struktury tokenu,

Seznam tokenů

Tokeny z lexikální analýzy jsou ukládány do **obousměrně vázaného seznamu** `DLListTokens`, který předává lexikální analýza syntaktické analýze.

Struktura `DLListTokens` drží:

- `first` – první prvek seznamu,
- `active` – aktuálně zpracovávaný token,
- `last` – poslední prvek,
- `length` – počet prvků.

Používané operace:

- `DLLTokens_Init()`, `DLLTokens_Dispose()` – vytvoření a uvolnění seznamu,
- `DLLTokens_InsertFirst()`, `DLLTokens_InsertLast()` – vložení tokenu na začátek/konec,
- `DLLTokens_First()`, `DLLTokens_Next()` – pohyb aktivního prvku,
- `get_token_type_ignore_eol()` – vrátí typ dalšího neprázdného tokenu, přeskakuje `T_EOL`.

5.6 Syntaktický strom

Struktury v `ast.h`:

- Struktura syntaktického stromu je definována v souboru `ast.h` Strom je vytvořen v rámci syntaktické analýzy a je využíván v celém zbytku kompilátoru. Struktura je složena z hlavní struktury textttast, která obsahuje prolog a ukazatel na třídu Program.
- Struktura `ast_class` obsahuje ukazatel na případnou další třídu, Jméno třídy a ukazatel na `ast_block`, který obsahuje tělo třídy.
- Struktura `ast_block` slouží, jako tělo funkce/třídy/podmínky/cyklu i samostatně odděleného bloku. Každý blok má ukazatel na první, aktuálně zvolený a následující `ast_node`(příkaz/konstrukci) a ukazatel na nadřazený blok.
- Struktura `ast_node` obsahuje jeden příkaz/konstrukci vstupního kódu a všechny důležité informace.

- Struktura `ast_function` obsahuje název funkce, její parametry a blok s tělem funkce.
- Struktura `ast_expression` se dosti podobá struktuře `ast_node`, jelikož se jedná o kolekci identifikátorů, volání funkcí, identit, unárních a binárních výrazů. Slouží pro vytváření složitějších výrazů.
- Struktura `ast_parameter` obsahuje jméno/hodnotu parametru a odkaz na další parametr. Slouží především pro volání funkcí.
- Struktura `ast_ifj_function` slouží, pro označení speciálních vestavěných funkcí IFJ. Obsahuje jméno funkce a odkaz na první parametr.
- Struktura `ast_fun_call` je ekvivalentní struktuře `ast_ifj_function`, ale pro uživatelsky vytvořené funkce.

5.7 Generátor kódu

Generátor kódu je struktura obsahující vnitřní counter pro vytváření návěští, již popisovaný dynamický řetězec pro výstupní kód a zísobník pro ukládání zanořených návěští cyklů pro příkazy `break` a `continue`.

6 Závěr

Cílem projektu bylo vytvořit překladač pro jazyk IFJ25, který je podmnožinou jazyka Wren, do cílového jazyka IFJ25Code. Projekt zahrnuje lexikální, syntaktickou a sémantickou analýzu, generování kódu a jeho interpretaci. Hlavní část překladače byla úspěšně realizována a dokáže zpracovat základní konstrukce jazyka podle specifikace.

Výsledný překladač má nedostatky zejména v oblastech rozšířených funkcí, kde nejsou plně implementována všechna požadovaná pravidla. Problémem jsou i zanořené cykly. Klíčová funkcionalita jádra překladače však funguje spolehlivě.

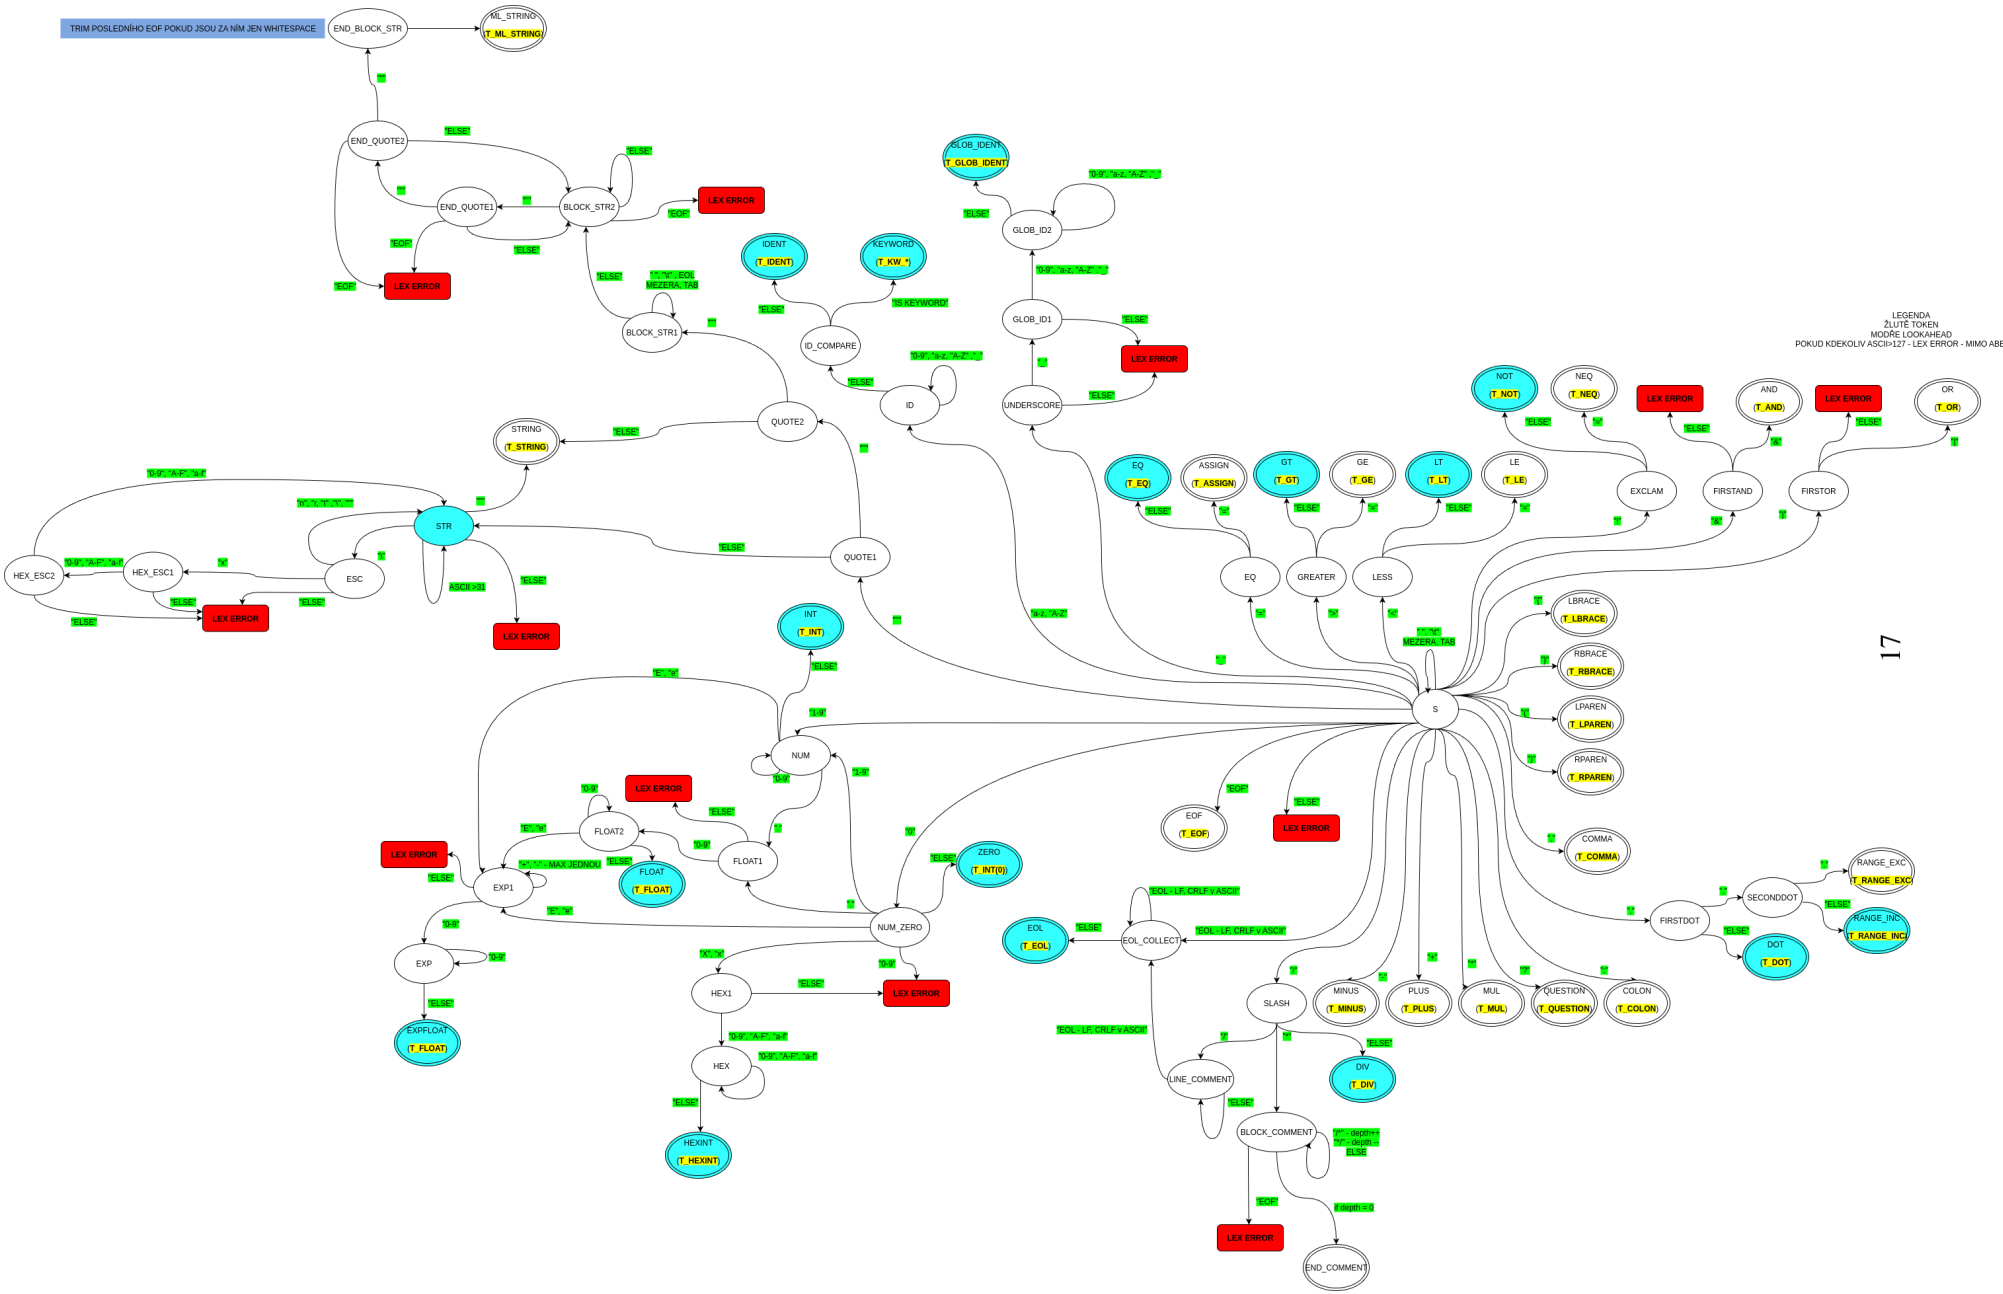
TRIM POSLEDNÍHO EOF POKUD JSOU ZA NÍM JEN WHITESPACE
END_BLOCK_STR
ML_STRING
(T_ML_STRING)
END_QUOTE2
END_QUOTE1
BLOCK_STR2
BLOCK_STR1
LEX ERROR
IDENT
(T_IDENT)
KEYWORD
(T_KW_*)
ID_COMPARE
ID
GLOB_IDENT
(T_GLOB_IDENT)
GLOB_ID2
GLOB_ID1
UNDERSCORE
QUOTE2
QUOTE1
STRING
(T_STRING)
STR
HEX_ESC2
HEX_ESC1
ESC
INT
(T_INT)
NUM
FLOAT2
FLOAT1
EXP1
FLOAT
(T_FLOAT)
EXP
EXPFLOAT
(T_FLOAT)
NUM_ZERO
ZERO
(T_INT(0))
HEX1
HEX
HEXINT
(T_HEXINT)
S
EQ
ASSIGN
(T_ASSIGN)
GT
(T_GT)
GE
(T_GE)
LT
(T_LT)
LE
(T_LE)
NOT
(T_NOT)
NEQ
(T_NEQ)
AND
(T_AND)
OR
(T_OR)
EXCLAM
FIRSTAND
FIRSTOR
GREATER
LESS
LBRACE
(T_LBRACE)
RBRACE
(T_RBRACE)
LPAREN
(T_LPAREN)
RPAREN
(T_RPAREN)
COMMA
(T_COMMA)
FIRSTDOT
SECONDDOT
RANGE_EXC
(T_RANGE_EXC)
RANGE_INC
(T_RANGE_INC)
DOT
(T_DOT)
EOF
(T_EOF)
EOL
(T_EOL)
EOL_COLLECT
SLASH
MINUS
(T_MINUS)
PLUS
(T_PLUS)
MUL
(T_MUL)
QUESTION
(T_QUESTION)
COLON
(T_COLON)
DIV
(T_DIV)
LINE_COMMENT
BLOCK_COMMENT
END_COMMENT
LEGENDA
ŽLUTÉ TOKEN
MODŘE LOOKAHEAD
POKUD KDEKOLIV ASCII>127 - LEX ERROR - MIMO ABECEDU
17